

Organisation des données

Une couche brute dans MongoDB, une couche exploitable dans PostgreSQL, reliées par une clé métier

1. Ce que l'étape demandait

Choisir où stocker les données collectées, concevoir le modèle de données et écrire le chargement, en justifiant le choix des bases et la façon dont elles se relient.

2. Nos choix et pourquoi

Choix	Pourquoi	Alternative écartée
Répartir selon la forme de la donnée	une bougie a toujours 13 colonnes : relationnel ; les métadonnées de Binance ont des champs variables et imbriqués : documents	« SQL pour l'historique, NoSQL pour le temps réel », alors que la bougie est la même
PostgreSQL pour la couche exploitable	transactions, jointures, contraintes qui refusent une donnée incohérente ; 2 millions de lignes restent loin de ses limites	InfluxDB, ClickHouse : faits pour des milliards de lignes, sans transactions
Extension TimescaleDB	découpe les bougies en tranches de temps, compresse les anciennes ; fournie dans l'image Docker officielle	Snowflake, BigQuery : payants et hébergés, hors conteneurs
MongoDB pour la couche brute	garde les réponses de Binance telles quelles, pour rejouer un nettoyage corrigé	Elasticsearch, conçu pour la recherche
Clé métier (paire, pas de temps, ouverture)	identifie une bougie par ce qui la définit ; aucun doublon possible	un identifiant technique
Champ <code>raw_ref</code> sur chaque bougie	aucun moteur ne pose de clé étrangère vers l'autre ; on remonte ainsi au document brut d'origine	deux bases sans lien vérifiable
Une table par profil, lue par des vues	chaque pas de temps stocké une fois ; compression réglée par profil	une table unique
Chargement idempotent	une bougie présente est mise à jour, jamais dupliquée : relancer ne crée aucun doublon	une insertion simple

Les variables calculées à l'étape 3 sont stockées en JSONB plutôt qu'en colonnes : leur nombre a changé plusieurs fois, et chaque essai aurait demandé une migration du schéma.

3. Résultat

- 2 075 570 bougies chargées dans trois tables de profil, protégées par des contraintes (prix cohérents, volumes positifs, source connue).
- Quatre collections MongoDB, dont un carnet d'ordres effacé automatiquement après 30 jours.
- Le modèle a accueilli les besoins des étapes 3 à 5 sans refonte, par des fichiers SQL numérotés.

4. Limite

Le lien entre les deux bases repose sur la clé métier et sur `raw_ref` : aucun moteur ne le vérifie, c'est au chargement de l'écrire correctement.