

Machine learning

Un modèle qui prédit le sens de la prochaine bougie, mesuré sur des données qu'il n'a jamais vues

1. Ce que l'étape demandait

Entraîner plusieurs modèles sur les données stockées, les comparer, optimiser le meilleur et l'exporter pour l'API, en suivant les expériences avec MLflow.

2. Nos choix et pourquoi

Choix	Pourquoi	Alternative écartée
Prédire le sens de la prochaine bougie (day trading)	cible simple et mesurable, objectif fixé à 60 % de bonnes réponses	le prix, où un modèle naïf atteint un R^2 de 0,999998 ; les trois barrières, au sens juste à 50,6 %
Un modèle qui peut s'abstenir	il n'agit qu'au-delà d'un seuil de probabilité, réglé par style (agressif ou conservateur)	se prononcer sur chaque bougie
Extrait figé signé (SHA-256)	la base change chaque jour ; le même script doit donner le même modèle	entraîner sur la base vivante
Découpage chronologique	apprendre sur le passé, tester sur le futur	un découpage aléatoire
35 variables sans unité, avec le contexte 1 h et 4 h	un prix brut appris ne vaut ni pour une autre paire ni l'année suivante	les 86 colonnes de la bibliothèque <code>ta</code> , très redondantes
Forêt aléatoire calibrée	meilleure en validation ; la calibration ajoute 1,5 à 1,7 point	gradient boosting, régression logistique
Une règle fixée avant les essais	une piste doit progresser à 2 % et à 5 % d'activité	garder ce qui marche sur une seule période

Cette rigueur a écarté trois faux résultats, dont une fuite de données : la bougie 4 h jointe n'était pas encore clôturée, et le score passait de 0,52 à 0,61. Un test automatisé l'empêche de revenir.

3. Résultat

- Sur 14 831 bougies jamais vues : 59,7 % de bonnes réponses en style agressif, 59,9 % en conservateur (intervalle à 95 % de 55,4 % à 64,3 %), avec 20 à 25 ordres par jour.
- Modèle exporté en `.joblib` avec ses 35 variables, ses seuils et l'empreinte de ses données ; chaque entraînement est tracé dans MLflow.

4. Limite

Le modèle a raison environ 60 % du temps mais n'est pas rentable : en 15 minutes, le prix bouge en moyenne de 0,227 % pour 0,2 % de frais par aller-retour, il faudrait 94 % de précision. Au backtest, il perd 3,6 à 5,0 % frais compris. La piste suivante est de ne prédire que les mouvements assez grands pour couvrir les frais.