

Récupération des données **Binance**

Quelles sources nous utilisons, comment nous récupérons les données, et à quoi elles ressemblent une fois nettoyées.

Dépôt DataScientest-Studio/jul26_bde_crypto

Date 28 août 2026

2 SOURCES UTILISÉES	5 PAIRES SUIVIES	262 415 BOUGIES COLLECTÉES	99,96 % DE DONNÉES COMPLÈTES
-------------------------------	----------------------------	--------------------------------------	--

01 Ce que nous collectons

Nous récupérons l'historique des cours de cinq crypto-monnaies sur Binance, sous forme de **bougies horaires**. Une bougie résume une heure de marché en quelques chiffres : prix d'ouverture, plus haut, plus bas, prix de clôture, et volume échangé.

CHOIX	VALEUR	POURQUOI
Plateforme	Binance	Premier exchange mondial, API publique gratuite, aucune inscription nécessaire pour les données de marché
Paires	BTC · ETH · BNB · SOL · XRP toutes contre USDT	Les cinq plus échangées. Un marché très actif donne des données propres et sans trous
Pas de temps	1 heure	À la minute, 3 millions de lignes par paire et beaucoup de bruit. À la journée, seulement 2 200 lignes : trop peu pour entraîner un modèle
Période	depuis septembre 2020	C'est SOL qui limite : la paire n'existe sur Binance que depuis août 2020

UNE PRÉCISION SUR LES PAIRES

On parle souvent de « BTC/USD », mais **ce marché n'existe pas sur Binance**. Le dollar y est remplacé par l'USDT, une crypto-monnaie dont la valeur suit le dollar. Toutes nos paires sont donc en USDT.

02 Comment nous récupérons les données

Binance propose deux moyens d'accès, et nous avons besoin des deux car ils ne répondent pas à la même question.

	API REST	WEBSOCKET
Principe	On pose une question, on reçoit une réponse	On s'abonne, on reçoit en continu
Répond à	Que s'est-il passé avant ?	Que se passe-t-il maintenant ?
On s'en sert pour	Constituer l'historique qui servira à entraîner le modèle	Alimenter le modèle en direct une fois en production

Les étapes de la récupération

1. **On demande la liste des paires** à Binance pour vérifier qu'elles existent et sont bien ouvertes aux échanges.
2. **On récupère les bougies par paquets de 1 000**, la limite imposée par Binance. Pour six ans d'historique, il en faut environ 53 par paire.
3. **On enchaîne les paquets** en repartant à chaque fois de la dernière bougie reçue, jusqu'à rattraper aujourd'hui.
4. **On nettoie les données** (section 03) et on les enregistre.
5. **En parallèle, on écoute le direct** via le WebSocket pour les nouvelles bougies.

Toute cette logique est écrite **une seule fois et fonctionne pour n'importe quelle paire**. Le nom de la crypto n'est écrit nulle part dans le code : c'est un paramètre. Ajouter une sixième paire ne demande aucune ligne de code supplémentaire.

```
python -m scripts.collect_history # les 5 paires du projet
python -m scripts.collect_history --paires ADAUSDT --intervalle 4h # n'importe quelle autre
```

DEUX PIÈGES RENCONTRÉS

Si on demande plus de 1 000 bougies, **Binance en renvoie 1 000 sans prévenir** — aucune erreur. C'est pour ça qu'on repart de la dernière bougie reçue et jamais d'un compteur, sinon on perdrait des données sans s'en apercevoir.

Binance limite aussi le nombre d'appels par minute. Notre collecte complète n'utilise que **9 % de ce qui est autorisé**, on est donc très loin de la limite.

03 À quoi ressemblent les données

C'est la partie la plus importante : les données brutes de Binance **ne sont pas utilisables telles quelles**.

```
[1787918400000,
  "79604.12000000",
  "79727.36000000",
  "79306.11000000",
  "79421.05000000",
  "400.05317000",
  1787921999999,
  "31801379.67835110",
  113842,
  "172.31828000",
  "13699285.03758190",
  "0"]
```

```
{"symbol": "BTCUSDT",
  "interval": "1h",
  "open_time": "2026-08-28T12:00:00Z",
  "close_time": "2026-08-28T12:59:59Z",
  "open": 79604.12,
  "high": 79727.36,
  "low": 79306.11,
  "close": 79421.05,
  "volume": 400.05317,
  "quote_volume": 31801379.68,
  "nb_trades": 113842,
  "taker_buy_base": 172.31828}
```

Trois problèmes à régler :


1. **Aucun nom de colonne.** Il faut savoir que la 5^e valeur est le prix de clôture. Nous nommons chaque colonne.
2. **Les prix sont du texte, pas des nombres.** Binance les envoie entre guillemets pour ne pas perdre de précision. Mais tant qu'ils restent du texte, aucun calcul n'est possible : l'ordinateur considère que "9000" est plus grand que "79600", comme dans un dictionnaire. Nous les convertissons en nombres.
3. **Les dates sont des nombres géants** (millisecondes depuis 1970). Nous les convertissons en vraies dates, en précisant le fuseau UTC — sans ça, tout l'historique se décale de deux heures.

Le direct pose un problème en plus

Le WebSocket renvoie la bougie en cours **à chaque fois qu'elle change**, soit une quinzaine de fois par minute. Une seule de ces versions est la bonne : celle où la bougie est terminée, signalée par un indicateur `x`.

MESURÉ SUR 200 SECONDES

500 messages reçus, 20 bougies réellement gardées. Sans ce filtre, on enregistrerait 96 % de doublons et des prix qui n'ont jamais été confirmés.



Les deux sources arrivent dans des formats différents mais ressortent identiques. La suite du projet n'a donc qu'un seul format à gérer.

04 Ce que nous avons obtenu

RÉSULTAT	VALEUR
Bougies collectées	262 415
Période couverte	sept. 2020 → août 2026
Temps de collecte	81 secondes
Lignes en double	0
Valeurs manquantes	0
Bougies absentes	20 par paire

Les 20 bougies manquantes

Nous avons cherché d'où venaient ces trous. Ils correspondent à **dix interruptions**, principalement fin 2020 et courant 2021.

LE POINT IMPORTANT

Ces dix interruptions tombent exactement aux mêmes dates sur les cinq paires. Si notre programme était en cause, les trous seraient différents d'une paire à l'autre. Le fait qu'ils soient identiques montre qu'il s'agit d'**arrêts de Binance** (maintenances), pas d'un problème de notre côté.

Conséquence : il ne faudra **pas** inventer de prix pour combler ces trous. Le marché était réellement fermé ; remplir ces heures créerait une information qui n'a jamais existé.

05 Questions pour la suite

1. **Sur quelle durée veut-on prédire ?** Une décision d'achat à 1 h, 4 h ou 24 h ? C'est ce qui déterminera ce que le modèle doit apprendre, et il vaut mieux le fixer avant l'étape 3.
2. **Le pas d'une heure convient-il ?** Ou faut-il aussi collecter en 15 minutes pour comparer ?
3. **Que fait-on des dix interruptions ?** Les laisser telles quelles, ou les signaler explicitement dans la base ?