

Récupération des données **Binance**

Quelles sources nous utilisons, comment nous récupérons les données, et à quoi elles ressemblent une fois nettoyées. Cette version couvre trois profils de trading là où la première n'en couvrait aucun explicitement.

Dépôt DataScientest-Studio/jul26_bde_crypto

Date 29 août 2026

3 PROFILS DE TRADING	7 PAS DE TEMPS	35 JEUX DE DONNÉES	2 075 570 LIGNES COLLECTÉES
--------------------------------	--------------------------	------------------------------	---------------------------------------

00 Historique des versions

La version 1 reste consultable telle qu'elle a été rendue le 28 août. Ce document la remplace ; la section 05 détaille ce qui a changé et pourquoi.

VERSION	DATE	PÉRIMÈTRE	CE QUI A MOTIVÉ LE CHANGEMENT
v1	28 août 2026	Un seul pas de temps : 1 heure, depuis sept. 2020	Livrable initial de l'étape 1
v2	29 août 2026	7 pas de temps répartis sur 3 profils de trading	Un bot ne regarde pas le marché à la même échelle selon la stratégie visée

	V1	V2
Jeux de données	5	35
Pas de temps	1	7
Lignes collectées	262 415	2 075 570
Volume (Parquet)	20,2 Mo	131,8 Mo
Durée de collecte	81 s	637 s

01 Ce que nous collectons

Nous récupérons l'historique des cours de cinq crypto-monnaies sur Binance, sous forme de **bougies**. Une bougie résume une tranche de temps en quelques chiffres : prix d'ouverture, plus haut, plus bas, prix de clôture, et volume échangé.

CHOIX	VALEUR	POURQUOI
Plateforme	Binance	Premier exchange mondial, API publique gratuite, aucune inscription nécessaire pour les données de marché
Paires	BTC · ETH · BNB · SOL · XRP toutes contre USDT	Les cinq plus échangées. Un marché très actif donne des données propres
Pas de temps	7, selon le profil	Voir le tableau des profils ci-dessous
Période	variable selon le pas	De 180 jours pour le scalping à six ans pour le swing

UNE PRÉCISION SUR LES PAIRES

On parle souvent de « BTC/USD », mais **ce marché n'existe pas sur Binance**. Le dollar y est remplacé par l'USDT, une crypto-monnaie dont la valeur suit le dollar. Toutes nos paires sont donc en USDT.

Les trois profils de trading

C'est l'apport principal de cette version. Un bot ne regarde pas le marché à la même échelle selon la stratégie visée : un scalpeur travaille à la minute, un swing trader à la semaine. Chaque profil définit donc ses pas de temps **et** sa profondeur d'historique.

PROFIL	PAS DE TEMPS	HISTORIQUE	POURQUOI CETTE PROFONDEUR
Scalping	1m 5m 15m	180 j	Positions de quelques minutes. Au-delà de quelques mois, la façon dont le marché s'échange a trop changé pour rester pertinente à cette échelle
Day trading	15m 1h 4h	730 j	Positions ouvertes et fermées dans la journée. Deux ans couvrent plusieurs régimes de marché — hausse, baisse, stagnation — sans noyer le modèle sous le bruit
Swing	4h 1d 1w	tout	Positions tenues plusieurs jours à plusieurs semaines. Une bougie hebdomadaire ne produit que ~50 lignes par an : il faut tout l'historique pour avoir de quoi entraîner

UN POINT DE CONCEPTION À EXPLIQUER

Le pas 15m est réclamé par deux profils, mais sur des profondeurs différentes : 180 jours pour le scalping, 730 pour le day trading. Nous retenons **la plus longue** — collecter large satisfait les deux profils, l'inverse laisserait le day trading à court de données. Même logique pour 4h, partagé entre day trading et swing, qui hérite donc de tout l'historique.

Le résultat n'est donc pas 9 collectes (3 profils × 3 pas de temps) mais **7**, une par pas de temps distinct.

Pourquoi l'historique démarre en septembre 2020

C'est **SOL** qui limite : la paire n'existe sur Binance que depuis août 2020. BTC et ETH remontent à 2017, mais aligner les cinq paires sur une base commune est indispensable dès qu'on voudra comparer les cryptos entre elles à l'étape 3. Un historique plus long sur BTC seul aurait produit des trous béants sur les autres colonnes.

02 Comment nous récupérons les données

Binance propose deux moyens d'accès, et nous avons besoin des deux car ils ne répondent pas à la même question.

	API REST	WEBSOCKET
Principe	On pose une question, on reçoit une réponse	On s'abonne, on reçoit en continu
Répond à	Que s'est-il passé avant ?	Que se passe-t-il maintenant ?
On s'en sert pour	Constituer l'historique qui servira à entraîner le modèle	Alimenter le modèle en direct une fois en production

Les étapes de la récupération

1. **On demande la liste des paires** à Binance pour vérifier qu'elles existent et sont bien ouvertes aux échanges.
2. **On détermine quoi collecter** à partir du ou des profils demandés : quels pas de temps, et depuis quelle date pour chacun.
3. **On récupère les bougies par paquets de 1 000**, la limite imposée par Binance. Pour le pas d'une minute sur 180 jours, il faut 260 paquets par paire.
4. **On enchaîne les paquets** en repartant à chaque fois de la dernière bougie reçue, jusqu'à rattraper aujourd'hui.
5. **On nettoie les données** (section 03) et on les enregistre.
6. **En parallèle, on écoute le direct** via le WebSocket pour les nouvelles bougies.

Toute cette logique est écrite **une seule fois et fonctionne pour n'importe quelle paire et n'importe quel pas de temps**. Ni le nom de la crypto ni l'intervalle ne sont écrits en dur : ce sont des paramètres.

```
python -m scripts.collect_history --list          # décrit les profils
python -m scripts.collect_history --profile scalping
python -m scripts.collect_history --profile all
python -m scripts.collect_history --pairs ADAUSDT --intervals 4h
```

DEUX PIÈGES RENCONTRÉS

Si on demande plus de 1 000 bougies, **Binance en renvoie 1 000 sans prévenir** — aucune erreur. C'est pour ça qu'on repart de la dernière bougie reçue et jamais d'un compteur, sinon on perdrait des données sans s'en apercevoir.

Binance limite aussi le nombre d'appels par minute. Même en collectant les 35 jeux, on reste très loin de la limite : le coût d'un appel est le même qu'on demande 1 bougie ou 1 000, donc on demande toujours 1 000.

03 À quoi ressemblent les données

C'est la partie la plus importante : les données brutes de Binance **ne sont pas utilisables telles quelles**.

CE QUE BINANCE ENVOIE

```
[1787918400000,
"79604.12000000",
"79727.36000000",
"79306.11000000",
"79421.05000000",
"400.05317000",
1787921999999,
"31801379.67835110",
113842,
"172.31828000",
"13699285.03758190",
"0"]
```

APRÈS NOTRE NETTOYAGE

```
{"symbol": "BTCUSDT",
"interval": "1h",
"open_time": "2026-08-28T12:00:00Z",
"close_time": "2026-08-28T12:59:59Z",
"open": 79604.12,
"high": 79727.36,
"low": 79306.11,
"close": 79421.05,
"volume": 400.05317,
"quote_volume": 31801379.68,
"nb_trades": 113842,
"taker_buy_base": 172.31828}
```

Trois problèmes à régler :

1. **Aucun nom de colonne.** Binance envoie toujours ses 12 valeurs dans le même ordre — c'est un contrat. On déclare la liste des noms une seule fois dans le code, et chaque nom se colle sur sa position.
2. **Les prix sont du texte, pas des nombres.** Binance les envoie entre guillemets pour ne pas perdre de précision. Mais tant qu'ils restent du texte, aucun calcul n'est possible : l'ordinateur considère que "9000" est plus grand que "79600", comme dans un dictionnaire.
3. **Les dates sont des nombres géants** (millisecondes depuis 1970). Nous les convertissons en vraies dates, en précisant le fuseau UTC — sans ça, tout l'historique se décale de deux heures.


Un quatrième point, moins visible : **la réponse ne contient ni la paire ni le pas de temps**. L'API suppose qu'on se souvient de sa propre question. Nous ajoutons donc ces deux colonnes nous-mêmes — sans elles, impossible d'empiler 35 jeux de données dans une même table à l'étape 2.

Le direct pose un problème en plus

Le WebSocket renvoie la bougie en cours **à chaque fois qu'elle change**, soit une quinzaine de fois par minute. Une seule de ces versions est la bonne : celle où la bougie est terminée, signalée par un indicateur `x`.

MESURÉ SUR 200 SECONDES

500 messages reçus, 20 bougies réellement gardées. Sans ce filtre, on enregistrerait 96 % de doublons et des prix qui n'ont jamais été confirmés.



Les deux sources arrivent dans des formats différents mais ressortent identiques. La suite du projet n'a donc qu'un seul format à gérer.

04 Ce que nous avons obtenu

2 075 570 lignes réparties sur **35 jeux de données** (7 pas de temps × 5 paires), collectées en **10 min 37 s**.

PAS DE TEMPS	DEPUIS	JEUX	LIGNES	COMPLÉTUDE	PARQUET
1m	2026-03-02	5	1 299 275	100 %	74,8 Mo
5m	2026-03-02	5	259 860	100 %	17,7 Mo
15m	2024-08-29	5	350 620	100 %	25,9 Mo
1h	2024-08-29	5	87 655	100 %	7,0 Mo
4h	2020-09-01	5	65 655	100 %	5,3 Mo
1d	2020-09-01	5	10 945	100 %	0,9 Mo
1w	2020-09-01	5	1 560	100 %	0,2 Mo

Zéro doublon, zéro valeur nulle, zéro incohérence de prix sur les 35 jeux.

Pourquoi 100 % ici, et 99,96 % en v1

La v1 annonçait 20 bougies manquantes par paire, correspondant à dix arrêts de la plateforme Binance. **Ces arrêts n'ont pas disparu** — mais ils ne sont plus visibles, pour deux raisons distinctes.

Première raison : la fenêtre a changé. Les dix pannes datent de 2020-2021 et de mars 2023. Le pas horaire démarre désormais en août 2024 : il passe simplement à côté. Ce n'est pas une amélioration de la qualité, juste une période différente.

Seconde raison, plus intéressante : les pannes sont absorbées par les pas de temps longs. Le 4h couvre pourtant bien 2021. Voici la panne du 25 avril 2021, où les heures 05:00, 06:00 et 07:00 sont absentes en pas horaire :

BOUGIE 4H	VOLUME	TRANSACTIONS
00:00	6 421 BTC	127 917
04:00	5,9 BTC	224
08:00	10 524 BTC	274 159

La bougie de 04:00 **existe** — parce qu'il y a eu 224 transactions avant que la plateforme lâche à 05:00. Binance produit donc une bougie 4 h, et le trou de trois heures disparaît du décompte. Il n'a pas disparu des données pour autant : il est **absorbé**, repérable seulement à un volume mille fois inférieur à la normale.

CE QU'IL FAUT EN RETENIR

La qualité mesurée dépend de l'échelle à laquelle on mesure. Les mêmes données affichent 99,96 % en pas horaire et 100 % en 4 h, sans qu'aucune ligne n'ait changé. Un taux de complétude n'a de sens qu'accompagné de sa granularité.

Conséquence pratique : il ne faudra **pas** inventer de prix pour combler les trous du pas horaire. Le marché était réellement fermé ; remplir ces heures créerait une information qui n'a jamais existé. Et il faudra se méfier des bougies à volume anormalement bas, qui signalent une panne sans la déclarer.

05 Ce qui a changé depuis la version 1

Les profils de trading

Avant : un seul pas de temps, 1 heure, choisi comme compromis entre le bruit du pas minute et la rareté du pas journalier.

Maintenant : trois profils couvrant sept pas de temps. Le compromis de la v1 n'était pas faux, mais il présupposait une stratégie de trading qui n'avait jamais été décidée. Tant que l'horizon de prédiction n'est pas arrêté, collecter les trois échelles laisse la décision ouverte au lieu de la préempter.

Le coût est modéré : 10 minutes de collecte et 132 Mo, au lieu de 81 secondes et 20 Mo.

Trois défauts corrigés

1. **La clé de déduplication ignorait le pas de temps.** Avec un seul pas, le problème était invisible. Dès qu'on collecte 1h et 4h, une bougie 1h et une bougie 4h ouvertes à la même heure étaient considérées comme la même donnée, et l'une écrasait l'autre.
2. **Le contrôle de complétude déduisait la durée d'une bougie depuis son nom.** Cela fonctionnait pour `1h` et `15m`, mais `1w` aurait planté. Remplacé par une table explicite couvrant les quatorze pas de temps de Binance.
3. **Le rapport qualité s'écrasait à chaque collecte.** Collecter une seule paire effaçait le bilan de toutes les autres. Il fusionne désormais avec les collectes précédentes.

Une convention de code

Le code est passé **en anglais** — noms de variables, de fonctions, de colonnes — tandis que **les commentaires et la documentation restent en français**. C'est la convention habituelle en Python, et cela évite les mélanges du type `normaliser_klines()`. Les commentaires servent à expliquer nos choix à l'équipe et au jury : ils restent dans notre langue.

06 Questions pour la suite

1. **Sur quelle durée veut-on prédire ?** Une décision d'achat à 1 h, 4 h ou 24 h ? C'est la question qui commande tout le reste : elle détermine la variable cible du modèle, et donc lequel des trois profils devient le profil principal. Elle devrait être tranchée avant l'étape 3.
 2. **Faut-il conserver les trois profils, ou n'en garder qu'un ?** Les garder tous coûte 132 Mo et laisse toutes les options ouvertes. N'en garder qu'un simplifierait le modèle de données de l'étape 2.
 3. **Que fait-on des dix interruptions ?** Les laisser telles quelles — notre recommandation — ou les signaler explicitement dans la base pour que le modèle sache qu'il ne s'agit pas de données normales ?
-