

Machine learning : ce que le marché laisse prédire

Comment nous avons entraîné, comparé et optimisé des modèles de décision d'achat, et ce que les mesures montrent réellement une fois les frais de transaction pris en compte.

Dépôt DataScientest-Studio/jul26_bde_crypto Date 11 septembre 2026

2,1 M LIGNES DANS L'EXTRAIT FIGÉ	6 × 3 MODÈLES × PROFILS COMPARÉS	30 EXÉCUTIONS SUIVIES DANS MLFLOW	3 FAUX RÉSULTATS DÉMONTÉS
---	---	--	--

01 En bref

LE RÉSULTAT EN UNE PHRASE


La volatilité du marché se prédit, sa direction non. Nos modèles savent reconnaître les moments où il ne va rien se passer, mais quand ils passent un ordre, ils ont le bon sens dans 50,6 % des cas, soit du pile ou face. Avec 0,2 % de frais par aller-retour, aucun des trois profils n'est rentable au backtest.

Ce résultat n'est pas un échec de la chaîne : c'est ce qu'elle a permis de mesurer proprement. La publication de référence que nous avons étudiée arrive à la même conclusion.

Ce qui était demandé, et où le trouver

DEMANDE	RÉALISÉ	OÙ
Extrait figé des données	OUI coupure au 24/08/2026, empreinte SHA-256	scripts/make_extract.py
Exploration (EDA)	OUI nuls, doublons, répartition des classes	section 02
Indicateurs techniques (ta)	OUI 26 variables sur 5 familles	src/features.py
Plusieurs modèles comparés	OUI 6 modèles, dont 2 références	scripts/compare_models.py
R ² , RMSE	OUI volet régression dédié	scripts/regression_baseline.py
GridSearchCV	OUI découpage chronologique	scripts/optimize_model.py
Stop loss / take profit	OUI intégrés à l'étiquetage	src/labeling.py
Export .joblib	OUI un modèle par profil	models/
MLflow	OUI 30 exécutions tracées	mlflow.db
Notebook	NON scripts Python testés à la place	à produire pour la présentation

02 La démarche et les données



Chaque étape consomme la sortie de la précédente. Le backtest est la seule qui répond en euros, et c'est lui qui tranche.

Un extrait figé, comme Rémy l'a demandé. Tous les modèles sont entraînés sur les mêmes 2 124 845 lignes, coupées au 24 août 2026. Chaque fichier a une empreinte SHA-256, vérifiée avant chaque entraînement et enregistrée dans MLflow. Sans cela, un score qui change d'une exécution à l'autre ne pourrait être ni comparé ni défendu.

Exploration des données

CONTRÔLE	RÉSULTAT	CONSÉQUENCE
Doublons	0	rien à corriger
Valeurs manquantes	0	seule la période de chauffe des indicateurs est retirée
Incohérences de prix	0	contrainte inscrite dans le schéma SQL
Répartition des classes	31 à 36 %	trois classes équilibrées, pas de rééquilibrage nécessaire

03 Ce que le modèle apprend

Pas le prix : le prix donne un score trompeur

Le premier réflexe est de prédire le prix de la bougie suivante. Nous avons mesuré ce que cela donne, en comparant à un modèle naïf qui répond simplement « le prochain prix sera le prix actuel » :

MODÈLE (SCALPING)	R ² SUR LE PRIX	R ² SUR LE RENDEMENT
Modèle naïf, qui ne calcule rien	0,999998	-0,000329
Gradient boosting	0,974495	-0,012248
Ridge	-0,172939	-0,021623

Un modèle qui recopie son entrée obtient 0,999998, et les vrais modèles font moins bien que lui. Ce R² mesure surtout que le BTC coûte à peu près le même prix qu'une heure plus tôt. Transformée en décision d'achat, la prédiction de prix donne **49,4 % de bons sens** sur BTC en 1 heure : son erreur médiane (13 311 €) est cent fois plus grande que le mouvement à prévoir (121 €).

Le mouvement, avec les trois barrières

Nous prédisons donc le mouvement, avec la méthode des trois barrières (López de Prado, 2018). Pour chaque bougie, on pose un **take profit**, un **stop loss** et une **échéance**. Celle qui est touchée en premier donne l'étiquette : acheter, vendre, ou attendre. Le stop loss et le take profit ne s'ajoutent donc pas après le modèle : ils définissent ce qu'il apprend.

DES BARRIÈRES QUI SUIVENT LE MARCHÉ

Les barrières sont placées à un multiple de la volatilité récente, notée σ . Le même réglage « 2σ » place le take profit à **+68 €** un jour calme (BTC à 63 022 €, le 16/08/2026) et à **+3 576 €** un jour agité (BTC à 103 931 €, le 20/01/2025). Un seuil fixe en euros n'aurait pas de sens d'une période à l'autre.

04 Les variables

La librairie `ta` propose une fonction qui ajoute tous ses indicateurs d'un coup. Nous ne l'avons pas utilisée : elle produit 86 colonnes dont **231 paires quasi identiques** (corrélation supérieure à 0,95), et deux colonnes vides à plus de 45 %. Un simple `dropna()` ramenait alors 2 184 lignes à **zéro**.

Nous avons retenu **26 variables**, toutes **sans échelle** : des rapports et des pourcentages, jamais un prix brut. Un modèle qui apprendrait « le BTC vaut 63 000 € » serait inutilisable sur l'ETH à 3 000 €, et sur le BTC l'année suivante.

FAMILLE, UTILISÉE SEULE	SCALPING	DAY TRADING	SWING
Volatilité	0,3989	0,4137	0,3891
Tendance	0,3641	0,3740	0,3602
Momentum	0,3545	0,3751	0,3798
Volume	0,3555	0,3819	0,3566
Flux acheteur (Binance)	0,3384	0,3361	0,3409
Hasard	0,3376	0,3354	0,3355

La volatilité domine partout. Mais c'est en partie mécanique : les barrières sont elles-mêmes calculées à partir de la volatilité, donc le modèle voit indirectement où sont ses cibles. Les variables de flux acheteur, propres à Binance, n'apportent rien seules.

05 Les modèles comparés

Six modèles par profil, choisis avec la carte de scikit-learn, dont **deux références** : toujours répondre la classe la plus fréquente, et répondre au hasard. Le découpage est chronologique : on entraîne sur le passé et on teste sur les 20 % les plus récents.

PROFIL	MEILLEUR MODÈLE	ACCURACY	GAIN SUR LA RÉFÉRENCE
Scalping	Régression logistique	0,4149	+0,0773
Day trading	Gradient boosting	0,4233	+0,0879
Swing	Forêt aléatoire	0,3972	+0,0497

Aucun modèle ne gagne partout, ce qui justifie d'en tester plusieurs par profil. Des modèles entraînés sur une seule paire font en revanche moins bien que le modèle commun, qui dispose de cinq fois plus de données.

Pourquoi l'accuracy trompe

Sur le day trading, l'accuracy vaut 0,4253 contre 0,33 pour le hasard. Cela semble bon. Mais elle compte toutes les bougies, y compris celles où le modèle dit « attendre » à raison. Nous mesurons donc aussi le **bon sens directionnel** : quand le modèle passe un ordre et que le marché bouge vraiment, a-t-il misé du bon côté ?

MESURE (DAY TRADING)	CALCUL	RÉSULTAT	HASARD
Accuracy	12 758 ÷ 30 000 bougies	0,4253	0,3333
Bon sens directionnel	8 262 ÷ 16 316 ordres	0,5064	0,5000

Mêmes prédictions, conclusion opposée. Le premier chiffre dit « le modèle fonctionne », le second dit « il ne prédit pas la direction ». Retirer les variables de volatilité fait baisser l'accuracy de 42,3 à 40,0 % mais laisse le bon sens à 50,3 % : elles aident seulement à repérer les phases calmes. **C'est le bon sens directionnel que nous optimisons ensuite.**

06 L'optimisation

GridSearchCV avec deux adaptations. Le critère optimisé est le bon sens directionnel, pas l'accuracy. Et la validation croisée utilise `TimeSeriesSplit` : le découpage par défaut mélangerait passé et futur, et le modèle s'entraînerait sur des données postérieures à celles qu'il doit prédire. Les grilles restent petites, comme conseillé.

PROFIL	VALIDATION	TEST	P-VALUE	VERDICT
Scalping	0,4970	0,5225	< 0,0001	significatif, mais instable
Day trading	0,5079	0,5064	0,0526	indistinguable du hasard
Swing	0,5245	0,5121	0,0129	significatif

Le scalping passe sous le hasard en validation et au-dessus en test : cette incohérence invite à la prudence. Surtout, sur le swing, les six combinaisons de paramètres testées donnent entre 0,5197 et 0,5245, soit **0,005 d'écart**. Les réglages ne changent quasiment rien : la limite vient du signal, pas du modèle.

07 Le backtest : ce que ça aurait rapporté

Le backtest rejoue les décisions du modèle sur la période de test avec **10 000 €**, une mise de 10 % par opération, des positions qui ne se chevauchent pas et **0,1 % de frais** à l'achat comme à la vente. Nous le comparons à un modèle parfait qui connaîtrait l'avenir, pour savoir si c'est la stratégie ou la prédiction qui échoue.

PROFIL (MODÈLE RETENU)	GAIN NET PAR OPÉRATION	CAPITAL FINAL	MODÈLE PARFAIT
Scalping	-0,18 %	5 007 € -49,9 %	+0,25 % / opération
Day trading	-0,23 %	3 540 € -64,6 %	+0,53 % / opération
Swing	—	8 218 € -17,8 %	+6,47 % / opération

Les trois profils perdent de l'argent, alors qu'un modèle parfait serait rentable partout. Les barrières contiennent donc du signal exploitable : c'est la prédiction de la direction qui échoue.

Les frais ferment la porte aux petits pas de temps

En 1 minute, avec des barrières à 2 σ , le gain médian d'une opération est de 0,10 %, pour 0,20 % de frais. Seules 15 % des opérations couvrent leurs frais, et même un modèle parfait n'y gagnerait pas. Une étude de CoinMetrics trouve 12 % sur des opportunités comparables. Le swing est le profil le plus proche de l'équilibre, mais son espérance de +0,07 % par opération se noie dans un écart-type de 7 % : il faudrait environ 77 000 opérations pour démontrer qu'elle n'est pas nulle, contre 934 sur la période de test.

08 Trois faux résultats démontés

Chercher à améliorer les résultats a produit trois résultats spectaculaires. Aucun n'a résisté à la vérification, et c'est sans doute la partie la plus utile de ce travail.

CE QUI SEMBLAIT MARCHER	CE QUE LA VÉRIFICATION A MONTRÉ
Contexte multi-échelles bon sens 0,5193 → 0,6136	Une fuite de données. Une bougie 4 h de midi recevait les indicateurs de la bougie journalière en cours, qui ne se termine qu'à minuit, soit 12 heures dans son futur. Une fois corrigé : 0,5207. Un test empêche désormais que cela revienne.
BNB, meilleure paire 0,5648, p < 0,0001	Une seule période favorable. Sur les périodes précédentes, BNB faisait 0,4272 et 0,4632, sous le hasard. Chaque paire est la meilleure à tour de rôle.
Classement des modèles par paire	Aucun pouvoir prédictif. La corrélation entre les classements de deux périodes successives vaut -0,24. Le dernier d'une période devient le premier de la suivante.

La leçon commune : une p-value calculée sur une seule période ne prouve rien. Seule la réplication sur d'autres périodes le fait.

Et l'étude de référence ?

Une publication de 2026 sur le Bitcoin annonce un ROC-AUC de 0,6086. Nous avons repris sa méthode (vote sur 54 combinaisons de stop loss et take profit) et reproduit son protocole : 0,5249 au mieux. L'écart reste inexpliqué, faute d'accès au texte complet. Mais **ses auteurs concluent eux-mêmes qu'un ROC-AUC de 0,60 est insuffisant** pour un signal de trading rentable. Leur étude ne contredit donc pas la nôtre.

09 Suivi MLflow et modèles exportés

			Metrics						
☐	Run Name	Created ↕	accuracy_global	backtest_gain_n	backtest_operati	backtest_perform	backtest_perte_r	bon_sens_direct	f1_macro
☐	swing_20260909_1622	2 minutes ago	0.4475	-0.1838	923	-17.82	-36.57	0.516	0.389368643...
☐	day_trading_20260909_16...	2 minutes ago	0.4253	-0.227	4564	-64.6	-64.75	0.5064	0.428227763...
☐	scalping_20260909_1621	2 minutes ago	0.4149	-0.1813	3811	-49.93	-50.02	0.5225	0.394412043...
☐	scalping_20260909_1620	4 minutes ago	0.4149	-0.1813	3811	-49.93	-50.02	0.5225	0.394412043...

Extrait de l'interface MLflow (vue « Training runs ») : chaque entraînement final et ses métriques, dont le bon sens directionnel et la performance du backtest. Les colonnes intermédiaires, identiques d'une ligne à l'autre, sont masquées. Les 30 exécutions comprennent aussi 20 combinaisons de GridSearchCV et 6 régressions.

Chaque exécution enregistre ses paramètres, ses métriques, le pipeline complet et l'empreinte de l'extrait figé. On peut donc dire, pour n'importe quel modèle, sur quelles données et avec quels réglages il a été entraîné.

FICHIER	MODÈLE	TAILLE
<code>scalping.joblib</code>	Régression logistique	4 ko
<code>day_trading.joblib</code>	Gradient boosting	1,1 Mo
<code>swing.joblib</code>	Forêt aléatoire	25,8 Mo

Chaque fichier contient le pipeline complet (imputation, normalisation, modèle), la liste des colonnes attendues et les réglages des barrières : c'est ce que l'API de l'étape 4 chargera. Le modèle swing, lourd, pourra être allégé à ce moment-là.

10 Conclusion

Nous avons construit une chaîne de machine learning complète et vérifiée : 63 tests automatisés, un extrait figé, des références systématiques et un backtest en euros. Elle aboutit à une conclusion nette : **la direction du prix n'est pas prévisible à partir des bougies passées, et les frais de transaction absorbent le peu d'avantage restant.**

C'est aussi ce que font ceux qui gagnent de l'argent avec des algorithmes : ils évitent ce problème. Les market makers encaissent l'écart entre prix d'achat et de vente sans parier sur une direction, et reçoivent des commissions au lieu d'en payer. Ce modèle leur est réservé : il demande des volumes de plusieurs centaines de millions de dollars par mois.

La suite

- **Étape 4** : une API FastAPI qui charge les modèles exportés, conteneurisée avec les bases, et une mesure de la dérive des données.
- **Étape 5** : automatiser la collecte et l'ingestion, une chaîne d'intégration continue qui fait tourner les 63 tests, et le suivi de l'application en production.